

文字探勘初論期末專案 政治新聞分類系統

蕭瑀
系級: 資管四
學號: B08705059

張力升
系級: 資管三
學號: B09705007

李彥澂
系級: 資管三
學號: B09705012

蔣詠心
系級: 資管三
學號: B09705020

許圃崧
系級: 資管三
學號: B09705027

陳亮妤
系級: 資管三
學號: B09705033

1 PURPOSE OF THE PROJECT

有鑒於我們這組的組員大多都是今年 11 月底九合一大選的首投族，剛獲得投票權的我們躍躍欲試，希望可以投下手中神聖的一票，但我們真的要好好把握我們手中的選票嗎？在選舉前一兩週，我們發現我們自己跟身邊的人對於政治似乎沒有太大的興趣。已經都快要選舉了，連總共有幾位市長候選人都不清楚，因此希望可以找出一種模式讓大家更接近政治、知道現在選情的熱度，以及更了解候選人，讓我們手中這一票不是隨便地投給任何一位看得順眼的人，而是真正了解過候選人看法、政見等做出的決定。

而新聞是最容易傳播資訊的媒體，也是傳遞資訊的主流管道。近幾年因網路科技發達，網路新聞崛起，數量非常地多，但每次在網站上總是只看得到一些存得亂七八糟，或是把相關的新聞放得很散的情況。

因為文字探勘初論期末報告主要著墨在文章的分類，還有可以利用爬蟲取得的特性，所以這次的期末專案選定以網路上的文

字新聞為主要資料來源，以其內容作為我們要判斷的文章。透過幫大家整理政治主題的新聞，把有相關的文本收集起來，用分類就可以讓大家很容易地使用我們網站，找到自己有興趣的關鍵字的相關新聞。

2 SOLUTION

為了不讓專案規模太大，這次專案先專注於「新竹市市長選舉」。

2.1 資料集

2.1.1 資料來源與範圍

資料來源為「自由時報」、「聯合報」的網站，範圍是報導發布時間介於 2022/6/1 到 2022/11/25、內容和新竹市長選舉相關的新聞。總共蒐集了 2787 篇新聞。

2.1.2 Label

我們根據報導的標題及內文所指涉的主題，在其中 1000 篇新聞上標了 Label。因為

新聞內容可能同時提及多個主題，我們決定讓每篇新聞可以有複數個主題，或者沒有主題。Label 總共有三種：

選情：單純分析選情之新聞。

事件：跟特定事件相關的新聞，事件例子為「林智堅論文抄襲爭議」、「高虹安助理費爭議」等。

政策：跟候選人提出的政見相關的新聞。

選擇這三個主題做為 label 並不是空穴來風：我們一開始的構想是專注於跟「政見」相關的新聞，把關於不同類型政見的新聞分類，好讓民眾查詢。例如民眾可以查「交通」，那麼就會出現關於「新竹輕軌」、「跨縣市大橋」等相關新聞。但後來遇到兩個問題，首先是台灣媒體對於候選人的政見並沒有太多著墨，蒐集資料有困難。後來我們改變方向變成分析「所有」新竹市長選舉的相關新聞，並分出大約 13 個類別，但後來發現政治新聞內容比較鬆散，13 個類別中有許多類別文章很少，訓練 SVM 的效果很差。最後才決定找三個最大的主題當作 Label。

2.2 Tokenization

因為文本內容為中文，因此我們選擇使用 Jieba 進行 tokenization。但 Jieba 主要是針對簡體中文，且我們使用的情境中會出現大量的政治詞彙，因此我們自己手動加入了 472 個詞彙幫助 tokenization。這些詞彙中包含了本次九合一選舉中常常出現的詞彙，例如「九合一」、「樁腳」、「公積金」、「三角督」等，也包含了跟台灣政治人物、政黨：「林耕仁」、「高虹安」、「沈慧虹」、「民進黨」、「國民黨」、「民眾黨」等等。增加這些詞彙後，Jieba 切出來的 token 大多都是正確的。

2.3 Vectorize

2.3.1 TF-IDF vector

我們使用 sklearn 提供的 TfidfVectorizer 將 2787 篇文章切出來的 token 轉換成 TF-IDF vector。最後的字典維度是 56175 維。

2.3.2 SVD vector

接下來我們使用 sklearn 提供的 TruncatedSVD 將 TF-IDF vector 轉成 SVD vector，將維度從 56175 維降成 100 維。

Classification

因為每篇文章可以有複數個主題，或是沒有主題，因此我們對「選情」、「事件」、「政策」這三個分別做二元分類。我們選擇使用 SVM 進行分類。

3 SYSTEM OUTCOMES

4 CONCLUSIONS

5 REFERENCES